




# PROGRAMACIÓN PARA LA CIENCIA DE DATOS

## CD106ICDA

Cuaderno de Ejercitación N° 2

Algoritmos para procesamiento y transformación de datos

## Instrucciones

Estimado/a estudiante

Te invitamos a poner a prueba tus conocimientos y habilidades en relación a los contenidos de esta Unidad 2 Algoritmos para procesamiento y transformación de datos. Si bien el desarrollo de este recurso formativo es opcional, te será muy útil para consolidar los aprendizajes adquiridos. Si decides ocuparlo, te recomendamos que vayas completando las actividades semana a semana, de acuerdo con lo indicado en cada apartado. Así podrás avanzar de forma paulatina, para una mejor comprensión y aplicación práctica de los distintos contenidos.

En esta ocasión, podrás ejercitar los contenidos y habilidades asociados a los siguientes indicadores de logro de la unidad.

### Resultado de Aprendizaje:

- Programa algoritmos para el procesamiento y transformación de datos.

Los indicadores de logro que se ejercitarán son los siguientes:

- Diseña algoritmos utilizando estructuras de control y funciones que resuelven problemas básicos de procesamiento y transformación de datos.
- Implementa en un lenguaje de programación (ej. Python, R, Java) algoritmos que realicen operaciones como limpieza, normalización, agregación y combinación de datos.
- Aplica técnicas de programación estructurada y modular para desarrollar algoritmos eficientes, garantizando claridad, legibilidad y reutilización del código.
- Valida algoritmos en distintos conjuntos de datos, de acuerdo a pruebas, evaluando su eficacia en la transformación de datos estructurados y no estructurados para su posterior análisis.

Recuerda que puedes revisar las **claves de respuesta** de cada actividad al final de este recurso, comprobando cuáles fueron tus aciertos y en qué podrías mejorar. Esperamos que puedas aprovechar al máximo este recurso para el aprendizaje y que sea de utilidad para tu proceso formativo.

¡Adelante y mucho éxito!

## 1. Resumen de la unidad (semana 5)

| Conceptos claves | Notas |
|------------------|-------|
|                  |       |

### Resumen



### Información complementaria

**Link 1:** Guía oficial de *pandas* que explica cómo detectar, eliminar y rellenar valores faltantes en DataFrames (usando `isnull()`, `dropna()`, `fillna()`, entre otros métodos). [https://pandas.pydata.org/docs/user\\_guide/missing\\_data.html](https://pandas.pydata.org/docs/user_guide/missing_data.html)

**Link 2:** Tutorial completo que enseña distintas técnicas para unir y combinar conjuntos de datos en *pandas*: `merge()`, `join()`, `concat()`. Incluye ejemplos claros y aplicaciones reales. <https://realpython.com/pandas-merge-join-and-concat/>

**Link 3:** Artículo que introduce el concepto de pseudocódigo, sus reglas, ventajas y ejemplos de uso, además de compararlo con diagramas de flujo. Muy útil para la fase de diseño algorítmico. <https://www.geeksforgeeks.org/what-is-pseudocode-a-complete-tutorial/>

## 2. Investigación y manejo de contenidos (semana 5)

### 2.1. Completar el cuadro comparativo.

| Criterio                                                    | Definición / Enfoque Teórico | Aplicación Práctica en Python |
|-------------------------------------------------------------|------------------------------|-------------------------------|
| 1. Diseño de algoritmos (pseudocódigo y diagramas de flujo) |                              |                               |
| 2. Preprocesamiento de datos                                |                              |                               |
| 3. Transformación y enriquecimiento                         |                              |                               |
| 4. Agregación y combinación de datos                        |                              |                               |
| 5. Validación y eficiencia del algoritmo                    |                              |                               |

### 2.2 Asociación de término con sus definiciones

**Instrucción:** Une cada término con la definición que mejor lo describe.

| Términos                          | Definiciones                                                                                                                                                                                                      |
|-----------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>A. Pseudocódigo</b>            | ( ) Representación intermedia de un algoritmo en lenguaje natural estructurado, que describe los pasos lógicos antes de escribir el código en un lenguaje de programación.                                        |
| <b>B. Outlier</b>                 | ( ) Valor atípico que se desvía considerablemente del resto de los datos; puede deberse a errores, condiciones excepcionales o fenómenos extremos.                                                                |
| <b>C. Normalización</b>           | ( ) Proceso que consiste en escalar los valores numéricos de un conjunto de datos dentro de un rango común, generalmente entre 0 y 1, para facilitar comparaciones o alimentar algoritmos sensibles a magnitudes. |
| <b>D. One-Hot Encoding</b>        | ( ) Método de codificación de variables categóricas que crea una columna binaria (0 o 1) por cada categoría, representando la presencia o ausencia de una etiqueta.                                               |
| <b>E. DataFrame</b>               | ( ) Estructura de datos bidimensional de la librería <b>pandas</b> , similar a una tabla, que permite almacenar y manipular datos en filas y columnas.                                                            |
| <b>F. Validación de algoritmo</b> | ( ) Etapa en la que se comprueba que los resultados obtenidos tras procesar o transformar datos sean coherentes con lo esperado, verificando totales, conteos y formatos.                                         |

### 2.3 Clasificar conceptos y ejemplificar

Clasifica las siguientes 5 actividades, da un ejemplo, luego explica brevemente por qué y cómo esa actividad impacta.

| Concepto                       | Definición | Clasificación / Tipo dentro del proceso de datos | Ejemplo aplicado (contexto) |
|--------------------------------|------------|--------------------------------------------------|-----------------------------|
| <b>Outlier (Valor atípico)</b> |            |                                                  |                             |
| <b>Normalización</b>           |            |                                                  |                             |
| <b>One-Hot Encoding</b>        |            |                                                  |                             |
| <b>GroupBy (Agrupamiento)</b>  |            |                                                  |                             |
| <b>Validación de algoritmo</b> |            |                                                  |                             |

### 3. Análisis y aplicación (semana 6)

#### Título del Caso / Problema: Análisis de Asistencia Escolar en Establecimientos Públicos

El Ministerio de Educación de Chile (Mineduc) ha entregado un conjunto de datos llamado `asistencia_2024.csv`, que contiene la siguiente información:

- RBD: Código del establecimiento escolar.
- Comuna: Nombre de la comuna donde se ubica el establecimiento.
- Mes: Mes del registro (en texto).
- Asistencia: Porcentaje promedio de asistencia de los estudiantes.
- Matricula: Número total de alumnos matriculados.

Al analizar el archivo, el equipo de datos detecta los siguientes problemas:

- Algunos valores de “Asistencia” están vacíos (NaN).
- Existen valores de asistencia superiores a 100% (error evidente).
- En algunas filas, el campo “Comuna” está duplicado con diferencias de formato (“Santiago” / “santiago”).
- Se requiere calcular la **asistencia promedio por comuna** y preparar los datos para un dashboard educativo.

#### Preguntas

1. Antes de escribir el código en Python, ¿cómo estructurarías el **algoritmo en pseudocódigo** para limpiar y procesar los datos correctamente?

---

---

---

---

Durante el preprocesamiento detectas 50 filas con Asistencia = NaN.

2. ¿Qué técnica aplicarías para tratar estos valores faltantes y por qué?

---

---

---

---

3. Se observan comunas escritas con mayúsculas y minúsculas diferentes (“Santiago”, “santiago”, “SANTIAGO”). ¿Qué tipo de transformación realizarías y qué método utilizarías en Python para resolverlo?

---

---

---

---

4. Después de limpiar los datos, se solicita calcular la **asistencia promedio por comuna**. ¿Qué función o método usarías en pandas y cómo validarías que los resultados sean correctos?

---

---

---

---

#### Fuentes o referencias

| Recurso / Título                           | URL                                                                                                                                                          | Breve descripción                                                                                                                                                                                                                                                  |
|--------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Pandas — documentación oficial             | <a href="https://pandas.pydata.org/docs/">https://pandas.pydata.org/docs/</a><br>(Pandas)                                                                    | Es la documentación oficial de la librería pandas, donde encontrarás información completa sobre estructuras (DataFrame, Series), manejo de valores faltantes, fusiones, agrupaciones, etc. Muy útil para profundizar en el uso de funciones vistas en esta unidad. |
| Pandas Tutorial — GeeksforGeeks            | <a href="https://www.geeksforgeeks.org/pandas-tutorial/">https://www.geeksforgeeks.org/pandas-tutorial/</a><br>(GeeksforGeeks)                               | Tutorial accesible que cubre aspectos como limpieza de datos, manipulación, agrupaciones y transformaciones con ejemplos claros. Buen recurso para ejercicios y repaso aplicado.                                                                                   |
| How to write a pseudocode? — GeeksforGeeks | <a href="https://www.geeksforgeeks.org/dsa/how-to-write-a-pseudo-code/">https://www.geeksforgeeks.org/dsa/how-to-write-a-pseudo-code/</a><br>(GeeksforGeeks) | Guía práctica sobre redacción de pseudocódigo: define qué es, por qué usarlo y cómo estructurarlo correctamente. Ideal para la fase de diseño de algoritmos previo a la codificación.                                                                              |

## Claves de Respuesta

En el siguiente QR puedes revisar las respuestas esperadas

**Referencia del presente documento:**

Instituto Profesional San Sebastián, Departamento Online (2025). Cuaderno de Ejercitación 2:  
*Algoritmos para procesamiento y transformación de datos. Programación para la ciencia de datos.*  
Santiago.