



INSTITUTO PROFESIONAL
SAN SEBASTIAN

PROGRAMACIÓN PARA LA CIENCIA DE DATOS

Sesión sincrónica

**INSTITUTO PROFESIONAL
ACREDITADO**



**GESTIÓN INSTITUCIONAL
DOCENCIA DE PREGRADO**
3 AÑOS / HASTA MARZO 2025



ACTIVIDADES

Apunte Activador

El Apunte Activador presenta una visión estructurada de Algoritmos para Procesamiento y Transformación de Datos

Esta unidad enseña a diseñar, programar y validar algoritmos que preparan los datos para su análisis. Se aborda el flujo completo de trabajo en ciencia de datos:

- Diseño de algoritmos: uso de pseudocódigo y diagramas de flujo para estructurar la lógica antes de codificar.
- Preprocesamiento: limpieza profunda, tratamiento de valores faltantes y detección de outliers.
- Transformación y enriquecimiento: normalización, codificación y conversión de formatos.
- Agregación y combinación: resumen y unión de datasets mediante funciones como `groupby()` y `merge()`.
- Validación y eficiencia: verificación de resultados y optimización del código.

Lenguaje principal: Python (pandas, NumPy, scikit-learn). El objetivo es transformar datos crudos en información útil, precisa y confiable, aplicando buenas prácticas de programación estructurada y modular.

Foro

Caso: “Datos de contaminación ambiental en Chile”

El Ministerio del Medio Ambiente está desarrollando un tablero de monitoreo de calidad del aire para distintas comunas de Chile.

Se cuenta con el archivo `calidad_aire_2024.csv`, que incluye las columnas:

- Comuna
- PM2.5 (partículas finas en $\mu\text{g}/\text{m}^3$)
- Fecha
- Sensor
- Estado (activo/inactivo)

Durante el análisis preliminar, el equipo detectó varios problemas:

- Algunas filas tienen PM2.5 con valores negativos o excesivamente altos.
- En varias observaciones, el campo “Comuna” aparece en distintos formatos (“La Florida”, “la florida”, “LAFlorida”).
- Hay sensores repetidos y registros duplicados.
- Algunas fechas están mal parseadas (texto en lugar de formato fecha).

1. ¿Por qué crees que es fundamental realizar un proceso de preprocesamiento de datos antes de analizarlos?
2. En este caso, ¿qué técnicas específicas aplicarías para detectar y corregir valores atípicos o extremos en la columna PM2.5?
3. ¿Qué métodos propondrías para estandarizar los nombres de las comunas y evitar duplicaciones al agrupar los datos?
4. ¿Cómo podrías validar que tu algoritmo de limpieza y transformación funciona correctamente y no eliminó datos válidos?



Caso - Problema

Presentación del caso/problema

Título del Caso / Problema: Análisis de Asistencia Escolar en Establecimientos Públicos

El Ministerio de Educación de Chile (Mineduc) ha entregado un conjunto de datos llamado `asistencia_2024.csv`, que contiene la siguiente información:

- RBD: Código del establecimiento escolar.
- Comuna: Nombre de la comuna donde se ubica el establecimiento.
- Mes: Mes del registro (en texto).
- Asistencia: Porcentaje promedio de asistencia de los estudiantes.
- Matricula: Número total de alumnos matriculados.

Al analizar el archivo, el equipo de datos detecta los siguientes problemas:

- Algunos valores de “Asistencia” están vacíos (NaN).
- Existen valores de asistencia superiores a 100% (error evidente).
- En algunas filas, el campo “Comuna” está duplicado con diferencias de formato (“Santiago” / “santiago”).
- Se requiere calcular la asistencia promedio por comuna y preparar los datos para un dashboard educativo.

1. Antes de escribir el código en Python, ¿cómo estructurarías el algoritmo en pseudocódigo para limpiar y procesar los datos correctamente?
2. ¿Qué técnica aplicarías para tratar estos valores faltantes y por qué?
3. Se observan comunas escritas con mayúsculas y minúsculas diferentes (“Santiago”, “santiago”, “SANTIAGO”). ¿Qué tipo de transformación realizarías y qué método utilizarías en Python para resolverlo?
4. Después de limpiar los datos, se solicita calcular la **asistencia promedio por comuna**. ¿Qué función o método usarías en pandas y cómo validarías que los resultados sean correctos?



INSTITUTO PROFESIONAL
SAN SEBASTIAN

PROGRAMACIÓN PARA LA CIENCIA DE DATOS

Sesión sincrónica

**INSTITUTO PROFESIONAL
ACREDITADO**



**GESTIÓN INSTITUCIONAL
DOCENCIA DE PREGRADO**
3 AÑOS / HASTA MARZO 2025