



INSTITUTO PROFESIONAL
SAN SEBASTIAN

PROGRAMACIÓN PARA LA CIENCIA DE DATOS. SESIÓN SINCRÓNICA TEÓRICA 2 ALGORITMOS PARA PROCESAMIENTO Y TRANSFORMACIÓN DE DATOS

**INSTITUTO PROFESIONAL
ACREDITADO**



**GESTIÓN INSTITUCIONAL
DOCENCIA DE PREGRADO
3 AÑOS / HASTA MARZO 2025**



- **Desarrollo de temas de la Unidad N°2:**
 - ✓ **Tema 1: Diseño de Algoritmos**
 - ✓ **Tema 2: Preprocesamiento de datos**
 - ✓ **Tema 3: Identificación de datos atípicos y faltantes.**
 - ✓ **Tema 4: Limpieza profunda de datos.**
 - ✓ **Tema 5: Transformación y enriquecimiento**
 - ✓ **Tema 6: Agregación y combinación de datos.**
 - ✓ **Tema 7: Validación de algoritmos.**
 - ✓ **Tema 8: Eficiencia y buenas prácticas**

Introducción



- En esta unidad aprenderás a diseñar, implementar y validar algoritmos que preparen datos para su posterior análisis.
- Se abordan conceptos clave como:
 - Diseño algorítmico.
 - Limpieza y preprocesamiento.
 - Transformación y enriquecimiento.
 - Agregación y combinación.
 - Validación y eficiencia.
- Lenguaje principal: Python con librerías pandas y NumPy.



UNIDAD 2

Diseño de algoritmos

- **Objetivo:** Planificar lógicamente el proceso antes de escribir código.
- **Herramientas:**
- **Pseudocódigo:** describe paso a paso las operaciones.
- **Diagramas de flujo:** visualizan decisiones y secuencias.

INICIO

Leer datos del archivo CSV

Limpiar valores nulos

Calcular promedio de columna

Mostrar resultados

FIN

Preprocesamiento de datos

- **Definición:** proceso de limpieza inicial para preparar los datos.
- **Etapas:**
 - Detección y tratamiento de **outliers**.
 - Manejo de **valores faltantes (NaN)**.
 - **Estandarización** de formatos.
 - Eliminación de **duplicados**.

EJEMPLO:

```
df = df.drop_duplicates()  
df['Edad'] = df['Edad'].fillna(df['Edad'].mean())
```

Identificación de datos atípicos y faltantes

- **Datos Atípicos (Outliers):** valores que se alejan significativamente del resto.
- **Técnica:** rango intercuartílico (IQR)
 - $Q1 = df['columna'].quantile(0.25)$
 - $Q3 = df['columna'].quantile(0.75)$
 - $IQR = Q3 - Q1$
 - $df_filtrado = df[(df['columna'] \geq Q1 - 1.5 * IQR) \& (df['columna'] \leq Q3 + 1.5 * IQR)]$
- **Valores faltantes:** imputar con media, mediana o moda.

Limpieza profunda de datos

- **Propósito:** garantizar coherencia y consistencia.
- **Operaciones frecuentes:**
 - Corrección de errores tipográficos.
 - Unificación de mayúsculas/minúsculas.
 - Ajuste de tipos de datos (`int`, `float`, `datetime`).

```
df['Comuna'] = df['Comuna'].str.title().str.strip()  
df['Fecha'] = pd.to_datetime(df['Fecha'])
```

Transformación y enriquecimiento

- **Objetivo:** adecuar los datos al modelo de análisis.
- **Transformaciones comunes:**
 - **Normalización:** escalar valores (0 a 1).
 - **Estandarización:** media = 0, desviación estándar = 1.
 - **Codificación:** variables categóricas → numéricas.

```
from sklearn.preprocessing import MinMaxScaler  
scaler = MinMaxScaler()  
df['Escalado'] = scaler.fit_transform(df[['Ingresos']])
```

Agregación y combinación de datos

- **Agregación:** resumen de datos (suma, media, conteo).
`df.groupby('Comuna')['Ingresos'].mean()`
- **Combinación (Merge/Join):** unir tablas relacionadas.
`pd.merge(df1, df2, on='Comuna', how='inner')`
- **Aplicación:** integrar datos de distintas fuentes (educación, salud, transporte, etc.).

Validación de algoritmos

- **Propósito:** verificar que el procesamiento haya sido correcto.
- **Estrategias:**
 - Comparar totales antes y después de la transformación.
 - Revisar distribuciones con gráficos.
 - Usar *assert* o tests unitarios.

```
assert df.shape[0] > 0
```

Eficiencia y buenas prácticas

- Evita bucles innecesarios → usa **operaciones vectorizadas**.
- Divide el código en **funciones reutilizables**.
- Documenta cada paso con comentarios.
- Evalúa complejidad temporal y espacial.

•**Ejemplo:**

```
def limpiar_datos(df):  
    df = df.drop_duplicates()  
    df = df.fillna(df.mean())  
    return df
```



Reflexión participativa

1. ¿Por qué crees que el diseño algorítmico previo (pseudocódigo o diagrama de flujo) puede marcar la diferencia entre un código eficiente y uno desordenado?
2. Piensa en un ejemplo real (educativo, social o laboral) donde la limpieza y transformación de datos sea fundamental para tomar decisiones. ¿Qué consecuencias tendría no realizar este proceso correctamente?
3. En tu opinión, ¿qué valor tiene la validación de algoritmos dentro del flujo de procesamiento de datos, y cómo contribuye a la calidad de los resultados finales?



Síntesis

- La correcta preparación de los datos es la base de todo análisis confiable en ciencia de datos.
- A lo largo de esta unidad aprendimos a diseñar algoritmos, limpiar y transformar datos, combinar distintas fuentes y validar los resultados para asegurar su calidad.
- Cada paso, desde el pseudocódigo hasta la validación final, contribuye a convertir el dato crudo en información útil y significativa.

Con estas herramientas, el estas preparado para abordar procesos de análisis más avanzados, garantizando que las decisiones basadas en datos sean precisas, éticas y fundamentadas en información de calidad.



INSTITUTO PROFESIONAL
SAN SEBASTIAN

PROGRAMACIÓN PARA LA CIENCIA DE DATOS. SESIÓN SINCRÓNICA TEÓRICA 2 ALGORITMOS PARA PROCESAMIENTO Y TRANSFORMACIÓN DE DATOS

**INSTITUTO PROFESIONAL
ACREDITADO**



**GESTIÓN INSTITUCIONAL
DOCENCIA DE PREGRADO
3 AÑOS / HASTA MARZO 2025**